

OS Agent 记忆优化 —— 完整技术路线图

赛题：XA-202612 麒麟OS Agent 记忆优化及高效应用研究

目标：挑战杯特等奖 / 擂台赛擂主

时间：2026年5月 ~ 9月15日


一、总体技术路线总图

```
flowchart TB
    subgraph DATA["数据层 (输入源)"]
        T1[工具执行结果]
        T2[用户行为数据]
        T3[手动配置信息]
    end

    subgraph ETL["整合层 (R1)"]
        E1[数据清洗]
        E2[格式标准化]
        E3[质量校验]
    end

    subgraph MEMORY["核心记忆层 (R2+R3)"]
        direction LR
        subgraph PREF["偏好记忆 R2"]
            P1[操作习惯提取]
            MemoryBank[遗忘曲线]
            P2[输出风格学习]
            AWM[工作流程模板]
            P3[安全策略记忆]
            P4[版本化管理]
            P5[跨场景适配]
            Rashomon[冲突解决]
        end
        subgraph KNOW["知识记忆 R3"]
            K1[工作流程模板]
            AWM
            K2[历史案例库]
            SAGE[自进化引擎]
            K3[知识图谱构建]
            HippoRAG[基座]
            K4[冲突消解]
            Entropic[Claim]
            K5[关联语义检索]
            EAM[可执行记忆]
        end
    end

    subgraph STORE["存储检索层 (R4+R6)"]
        S1[麒麟Embedding SDK]
        适配层
        S2[SHIMI层级索引]
        HNSW[HNSW向量索引]
        S3[BM25+向量]
        混合检索
        S4[MemReranker]
        推理感知重排序
    end
```



二、七层技术栈逐层拆解

R1 — 多源数据整合

目标：将工具执行结果、用户行为数据、手动配置信息整合为统一格式

技术路线：



学习资源：

类型	资源	链接	时长	说明
课程	DeepLearning.AI — Building Systems with ChatGPT API	deeplearning.ai	~1.5h	处理工具调用返回结果
工具	Pydantic 官方文档	docs.pydantic.dev	—	数据建模+自动校验，赛题最实用
教程	Kaggle — Data Cleaning	kaggle.com/learn/data-cleaning	~1h	pandas数据清洗实战
开源	Great Expectations	greatexpectations.io	—	数据质量验证（思路参考）

最新科研成果 (2025-2026):

论文	arXiv	核心贡献	与赛题关系
Towards Practical GraphRAG	2507.03226	高效KG构建+混合检索整合方法论	数据处理→KG构建的一体化流程参考
SAGE (Self-Evolving Agentic Graph-Memory)	2605.12061	记忆图谱自进化引擎	数据整合阶段的动态Schema设计


实战建议:

- 用 Pydantic BaseModel 定义统一数据Schema
- 用 Python dataclasses + json.dumps 做序列化
- 质量校验用正则+规则引擎（够用即可，不要上大框架）

R2 — 偏好记忆动态捕捉 重点创新

目标：自动提取用户操作习惯、输出风格、安全策略等偏好，支持版本化管理和跨场景适配

技术架构:



```
冲突消解]
  C4[版本化存储
  Git-like历史]
end
  subgraph OUTPUT["输出"]
    01[当前偏好参数]
    02[场景感知切换]
    03[偏好变更追溯]
  end
end
INPUT --> CORE
CORE --> OUTPUT
```

学习资源：

类型	资源	链接/说明	时长
必读论文	MemoryBank (AAAI 2024)	arXiv:2305.10250	精读2天
必读论文	AWM — Agent Workflow Memory (ICLR 2025)	arXiv:2409.07429	精读2天
必读论文	Reflexion (NeurIPS 2023)	arXiv:2303.11366	精读1天
课程	DeepLearning.AI — Advanced RAG	deeplearning.ai	~1.5h
课程	Stanford CS224U — NL Understanding	web.stanford.edu/class/cs224u/	完整课
工具	River ML — 漂移检测	riverml.xyz	—
综述	User Profiling in the Era of LLMs	arXiv:2407.01219	背景阅读

最新科研成果 (2025-2026)：

论文	arXiv/会议	核心贡献	与你赛题的关系
Rashomon Memory ☒	2604.03588	论证驱动的冲突视角——同一事件可能有多个合理的冲突解释，通过结构化论证解决	跨场景偏好冲突的直接方案！
MemoryBank (AAAI 2024)	2305.10250	艾宾浩斯遗忘曲线驱动——高频强化，低频衰减	偏好记忆动态捕捉的基础方案
AWM (ICLR 2025)	2409.07429	Agent从历史经验归纳可复用工作流程模板	用户操作模式学习——自动提取流程知识
PersonalAI 2.0 ☒	2605.13481	KG遍历前加入规划机制，先规划再检索	

论文	arXiv/会议	核心贡献	与你赛题的关系
			规划式个性化检索 ——更高效的用户偏好适配
PersonalizedAgent Survey	arXiv 2025	Agent个性化方法系统综述	快速建立领域全景

创新延伸方向：

- 1. **LLM驱动的偏好推理**：不依赖规则，用大模型分析行为序列自动发现隐式偏好
- 2. **时序遗忘曲线**：MemoryBank的曲线 + 自定义衰减权重（不同偏好类型不同衰减率）
- 3. **场景感知切换**：用轻量分类器识别当前场景，自动切换到对应偏好配置

R3 — 知识记忆结构化整合 ☒重点创新

目标：新旧知识冲突处理、关联检索优化，构建轻量可部署的知识记忆系统

技术架构：



学习资源：

类型	资源	链接/说明	时长
必读论文	HippoRAG (NeurIPS 2024)	arXiv:2405.14831	精读3天
必读论文	AriGraph (ACL 2024)	arXiv:2407.04363	精读2天
课程	DeepLearning.AI — Knowledge Graphs for RAG	deeplearning.ai	~1.5h
课程	Stanford CS520 — Knowledge Graphs	web.stanford.edu/class/cs520/	完整课
工具	NetworkX 官方教程	networkx.org	入门
工具	sqlite-vec	github.com/asg017/sqlite-vec	零依赖向量搜索

最新科研成果 (2025-2026):

论文	arXiv/会议	核心贡献	与赛题关系
SAGE	2605.12061	自进化的agentic图记忆引擎——能从部分线索恢复完整证据链，利用图结构角色，随时间自我改进	核心创新框架 ——记忆系统自我进化
EAM — Executable Agentic Memory	2605.12294	可执行的知识图谱记忆。将过去的交互存为结构化KG节点并支持可执行召回	OS Agent GUI操作记忆 的直接对标
MAGE	2605.10064	协同进化知识图谱——清晰表示Agent知识，独立于扁平情景记忆	知识冲突处理的进化视角
Entropic Claim Resolution	2603.28444	用熵/不确定性驱动的证据选择解决知识源冲突	新旧知识冲突处理的理论基础
EvolveMem	2605.13941	检索基础设施本身(评分函数、融合策略)也需要自进化	最前沿思想——检索系统与知识协同进化
Memanto	2604.22085	信息论驱动的类型化语义记忆检索	理论上更优的检索效率
Thinking Ahead	2605.14177	前瞻引导检索——Agent提前思考需要什么知识	主动式知识检索
GraphRAG-R1 (WWW 2026 CCF-A)	2507.23581	过程约束RL优化图遍历，学习最优多步检索策略	正式顶会发表的方法学引用

实现策略（端侧适配版）：

大模型方案 → 端侧降级方案

LLM提取三元组 → 规则模板 + 小模型(7B Q4)
冲突仲裁用LLM → 熵驱动统计 + 轻量分类器
全量KG遍历 → HNSW近似检索 + BM25兜底
在线增量更新 → 批量写入 + 定时重建索引

R4 — 端侧适配（≤500ms硬约束）

目标：调用麒麟Embedding SDK，实现≤500ms的检索响应

技术架构：

```
flowchart LR
    subgraph QUERY["查询"]
        Q1[用户查询]
    end
    subgraph EMBED["嵌入"]
        E1[麒麟SDK]
    end
    E1 -- "50-100ms" --> E2[缓存命中]
    E2 -- "0-5ms" --> SEARCH
    subgraph SEARCH["检索"]
        S1[HNSW索引]
        S2[BM25]
    end
    S1 -- "5-20ms" --> S2
    S2 -- "关键词兜底" --> RANK
    subgraph RANK["排序"]
        R1[MemReranker]
    end
    R1 -- "推理重排序" --> R2[混合融合]
    R2 -- "end" --> OUT[结果]
    Q1 --> EMBED
    EMBED --> SEARCH
    SEARCH --> RANK
    RANK --> OUT
```

≤500ms]

学习资源：

类型	资源	链接/说明	时长
课程	Cohere LLM University — Search 模块	docs.cohere.com/docs/text-search	~2h
	Pinecone — Vector Database 101	pinecone.io/learn/vector-database/	~2h

类型	资源	链接/说明	时长
课程			
工具	sqlite-vec	github.com/asg017/sqlite-vec	—
工具	LanceDB	lancedb.github.io	单文件向量库
工具	Faiss + HNSW	github.com/facebookresearch/faiss	核心索引
参考	MTEB Leaderboard	huggingface.co/spaces/mteb/leaderboard	看小模型表现
参考	ANN Benchmarks	ann-benchmarks.com	索引选型参考
课程	Stanford CS224N — QA Lecture 10	—	检索评估方法论

最新科研成果 (2025-2026):

论文	arXiv	核心贡献	与赛题关系
SHIMI ☒☒	2504.06135	统一语义层级记忆索引——支持不同粒度的高效检索	轻量化层级索引——端侧多粒度检索首选
MemReranker ☒☒	2605.06132	推理感知的重排序——专为 Agent 记忆设计，超越语义相似度	检索精度优化——500ms 约束下提高排序质量
Towards Practical GraphRAG ☒☒	2507.03226	可扩展且成本高效的 GraphRAG 企业部署	最直接的端侧可部署 GraphRAG 方案

500ms延迟预算（经可行性验证）：

步骤	串行时间	并行优化后	说明
麒麟SDK嵌入	50-100ms	50-100ms	不可跳过，缓存优化
HNSW向量检索	5-20ms	5-20ms	与SDK调用并行不可行
BM25兜底	0-10ms	0-10ms	与向量检索并行
重排序	50-100ms	0ms	小模型可选，可用规则替代

步骤	串行时间	并行优化后	说明
冲突检测/融合	30-50ms	30-50ms	
KG遍历	50-100ms	0ms	懒加载，首次请求后缓存
序列化返回	5ms	5ms	
总计	190-385ms	120-200ms	☑可行

R5 — 安全与遗忘

目标：敏感信息识别过滤 + NL指令驱动的精准遗忘

学习资源：

类型	资源	链接/说明
工具	Microsoft Presidio	github.com/microsoft/presidio
概念	Machine Unlearning 综述 (2024)	搜索关键词
概念	Right to be Forgotten in ML Systems	背景理解

最新科研成果 (2025-2026)：

论文	arXiv	核心贡献	与赛题关系
Agentic GraphRAG with Provenance ☑	2605.15109	Agentic GraphRAG中引用忠实性——agent探索KG后生成带引用的答案，引入遍历上下文和溯源追踪	知识来源可追溯——安全合规的关键！
EAM	2605.12294	可执行KG节点——删除节点即可精准遗忘	精准遗忘的基础操作支持


实现方案：

- 敏感信息过滤：Microsoft Presidio（规则+ML双模式）
- NL精准遗忘：NL指令→语义解析→定位KG节点/边→删除
- 溯源追踪：每条记忆记录来源ID，可回溯

R6 — 记忆流转

目标：短期→中期→长期记忆的自动流转

架构：



实现方案（直接参考已安装的 TencentDB 四层记忆架构）：

- L0: 原始对话/工具调用日志 → 短期
- L1: 抽取事实 → 中期
- L2: 场景识别 → 长期
- L3: 用户画像 → 长期

R7 — 量化评测

目标：标准化数据集 + 多指标验证 + 完整测试报告

学习资源：

类型	资源	链接/说明
课程	Stanford CS276 — Information Retrieval	web.stanford.edu/class/cs276/
参考	"Introduction to Information Retrieval" 在线版	nlp.stanford.edu/IR-book/
论文	IR评估：precision/recall/F1/MAP/NDCG	—

评测指标体系：

指标	目标值	说明
偏好提取准确率	≥85%	提取的用户偏好是否正确
知识检索召回率	≥85%	相关记忆是否被召回

指标	目标值	说明
检索响应延迟	≤500ms	端侧硬约束
冲突消解正确率	≥88%	冲突处理是否正确
遗忘准确率	—	NL指令→删除的正确率

三、学习路径总时间表

第1-2周（5月下旬） 基础扫盲

- └ AI Agent基础 + 记忆系统概念
- └ Generative Agents / MemGPT 论文初读
- └ 搭建开发环境

第3-5周（6月上旬） 核心技术学习

- └ R1: Pydantic + ETL pipeline
- └ R2: MemoryBank + AWM 精读
- └ R3: HippoRAG + NetworkX 实践
- └ R4: sqlite-vec + HNSW 搭建
- └ R5: Presidio 接入测试
- └ R6-R7: 接口设计 + IR评估

第6-8周（6月下旬-7月） 论文精读 + 创新方案

- └ SAGE / EAM / EvolveMem 等最新论文
- └ 确定核心创新点
- └ 系统架构设计定稿
- └ 开始编码

第9-12周（7-8月） 核心开发

- └ 逐模块编码实现

第13-16周（8-9月） 集成+优化+文档

四、论文精读清单 (按优先级)

Tier 1 — 必须先读（赛题直接对标）

论文	arXiv	会议	天数	对应要求
MemGPT	2310.08560	NeurIPS 2024 Oral	2天	整体架构
MemoryBank	2305.10250	AAAI 2024	2天	R2偏好记忆
HippoRAG	2405.14831	NeurIPS 2024	3天	R3知识检索

论文	arXiv	会议	天数	对应要求
AWM	2409.07429	ICLR 2025	2天	R2+R3
Generative Agents	2304.03442	UIST 2023 Best Paper	1天	奠基性

Tier 2 — 强力推荐（差异化创新来源）

论文	arXiv	日期	创新方向	推荐原因
SAGE	2605.12061	2026.5	自进化记忆引擎	评审眼中的"新颖性"亮点
EAM	2605.12294	2026.5	可执行KG记忆	OS Agent场景最匹配
EvolveMem	2605.13941	2026.5	检索基础设施自进化	前沿思想
Rashomon Memory	2604.03588	2026.4	冲突视角共存	偏好冲突解决方案
MemReranker	2605.06132	2026.5	推理感知重排序	检索精度优化
SHIMI	2504.06135	2025.4	层级记忆索引	端侧加速方案

Tier 3 — 扩展参考（有时间再看）

论文	arXiv	说明
Reflexion	2303.11366	反思机制
AriGraph	2407.04363	动态KG
GraphRAG-R1	2507.23581	WWW 2026 (CCF-A)
Thinking Ahead	2605.14177	前瞻检索
PersonalAI 2.0	2605.13481	规划式KG遍历
Entropic Claim	2603.28444	冲突仲裁理论
Memory3	2407.01178	清华/百川

--

五、论文获取渠道汇总

渠道	网址	用途
arXiv	arxiv.org	预印本，最新论文
Semantic Scholar	semanticscholar.org	AI论文搜索引擎，有引用图和TLDR

渠道	网址	用途
PapersWithCode	paperswithcode.com	论文+代码+数据集
Hugging Face Papers	huggingface.co/papers	每日论文推荐
AlphaXiv	alphaxiv.org	LLM优化的论文摘要
OpenReview	openreview.net	含审稿意见
Connected Papers	connectedpapers.com	论文关系图谱

六、核心技术学习路线详解

6.1 向量搜索 (Week 1-2)

学习链：Embedding基础 → 相似度计算 → HNSW索引原理 → 混合检索

- 推荐路径：
- 1. Cohere LLM University – Embeddings模块 (1h)
 - 2. Pinecone – Vector Database 101 – HNSW原理 (1.5h)
 - 3. 动手：用sqlite-vec搭建本地向量搜索demo (2h)
 - 4. Faiss官方教程 – IVF + HNSW (2h)
 - 5. MTEB Leaderboard看小模型排名 (0.5h)

6.2 知识图谱 (Week 2-3)

学习链：RDF三元组 → NetworkX → 图遍历算法 → PageRank

- 推荐路径：
- 1. NetworkX官方教程 – 创建图、遍历、查询 (1h)
 - 2. DeepLearning.AI – Knowledge Graphs for RAG (1.5h)
 - 3. HippoRAG论文精读 (3天)
 - 4. 动手：将工具调用记录转为三元组并存入NetworkX (3h)
 - 5. 实现Personalized PageRank遍历 (2h)

6.3 偏好学习 (Week 3-4)

学习链：用户画像 → 行为序列分析 → 漂移检测 → 场景聚类

- 推荐路径：
- 1. MemoryBank论文精读 (2天)
 - 2. AWM论文精读 (2天)
 - 3. River ML – 漂移检测算法ADWIN/Page-Hinkley (1h)

4. 动手：用遗忘曲线实现偏好更新demo（4h）

6.4 端侧部署优化 (Week 4-5)

学习链：模型量化 → ONNX Runtime → 索引优化 → 缓存策略

- 推荐路径：
- 1. ONNX Runtime CPU推理教程（2h）
 - 2. Faiss IVF-PQ量化索引（2h）
 - 3. ANN Benchmarks对比不同索引（1h）
 - 4. 动手：搭建250ms响应pipeline（4h）

七、必备工具链

工具	用途	安装/获取方式
Pydantic v2	数据建模+校验	<code>pip install pydantic</code>
NetworkX	轻量知识图谱	<code>pip install networkx</code>
sqlite-vec	零依赖向量搜索	<code>pip install sqlite-vec</code>
Faiss	高性能近似搜索	<code>pip install faiss-cpu</code>
sentence-transformers	文本嵌入	<code>pip install sentence-transformers</code>
Microsoft Presidio	PII检测	<code>pip install presidio-analyzer</code>
ONNX Runtime	模型推理加速	<code>pip install onnxruntime</code>
River ML	漂移检测	<code>pip install river</code>
LanceDB	端侧向量存储	<code>pip install lancedb</code>

注意：麒麟Embedding SDK是封闭的——你需要通过王雄老师联系祖老师获取。在获取之前，先拿 sentence-transformers 的 small 模型（如 all-MiniLM-L6-v2）做原型开发，后期替换。

八、创新点提炼一览

创新维度	具体方案	对标论文	技术难度
自进化记忆引擎	检索策略随使用自我优化	SAGE, EvolveMem	高
双模态冲突消解	偏好冲突(Rashomon) + 知识冲突(Entropic)统一框架	Rashomon, Entropic	中高
执行式记忆	KG节点支持可执行召回	EAM	中
推理感知检索	重排序阶段引入推理	MemReranker	中
遗忘曲线管理	不同类型偏好不同衰减率	MemoryBank	低
三层端侧加速	SHIMI + HNSW + 结果缓存	SHIMI, Practical GraphRAG	中

评分匹配（初评30分技术创新性）：

- EAM + SAGE 路线 → 15分（算法创新）
- Rashomon + Entropic 冲突消解 → 8分（方法创新）
- 端侧三层加速 → 7分（工程创新）
- **合计：预计28-30分** — 有竞争力

九、关键风险与应对

风险	概率	影响	应对
麒麟SDK延迟过高	中	高	本地索引缓存 + 异步更新
麒麟SDK获取延迟	中	高	先拿sentence-transformers做原型，留1周替换缓冲
SOTA方案依赖大模型	高	中	规则+小模型混合降级
评测数据集缺失	中	中	自建合成数据 + 借鉴MemGPT/MemoryBank开源评测
团队技术能力不足	中	中	AI辅助开发 + 模块划分细化

本文档整合了赛题分析、SOTA论文调研、学习路线三份文件的核心内容。最新论文更新截止2026年5月21日。

本文档生成日期：2026年5月21日 | 赛题：XA-202612 麒麟OS Agent 记忆优化及高效应用研究